

Automatska klasifikacija filmskih žanrova na osnovu sinopsisa

1. Definicija problema

Problem koji treba rešiti je razvoj algoritma za automatsko određivanje žanra filma na sinopsisa filma. Ovaj problem zahteva korišćenje tehnika obrade prirodnog jezika kako bi se analizirali tekstualni opisi klasifikovali u odgovarajući žanr filma. Cilj je stvoriti tačan i precizan algoritam koji može automatski dodeliti žanr filma, što bi omogućilo efikasnije kategorizovanje filmova i olakšalo korisnicima pretragu i preporuke filmova.

2. Motivacija

Rešenje ovog problema može značajno poboljšati brzinu i preciznost pretrage filmova na online platformama. Koristeći ovaj algoritam, korisnici ne moraju unapred znati tačan žanr filma koji traže. Umesto toga, mogu opisati sadržaj koji ih interesuje, a algoritam će analizirati taj tekst i dodeliti odgovarajući žanr. Na taj način, korisnicima će biti olakšano pronalaženje žanra koji odgovaraju njihovim zahtevima, bez potrebe da unose specifične ključne reči ili žanrove.

3. Skup podataka

Korišćen je javno dostupan skup podataka sa platforme *Kaggle* [1], koji sadrži:

- **Broj instanci:** 54.200 filmova
- **Atribut:** naslov filma, opis (sinopsis) spojeni u jedan tekstualni atribut
- **Ciljna klasa:** žanr filma, koji mogu biti dokumentarac, drama, komedija i horor


Skup podataka podeljen je na:

- **trening skup (65%)**
- **validacioni skup (15%)**
- **testni skup (20%)**

[Tabela I](#) prikazuje broj filmova po žanrovima u trening skupu podataka, pružajući tačan uvid u raspodelu klasa. Histogram na [slici 1](#) ilustruje istu distribuciju, naglašavajući nebalans među klasama.

Žanr	Broj filmova	Procenat
Dokumentarac	16043	37%
Drama	2601	6%
Komedija	18645	43%
Horor	6071	14%

Tabela I: Raspodela žanrova u trening skupu podataka



Slika 1: Distribucija broja filmova po žanrovima u trening skupu podataka

Pošto je distribucija žanrova u skupu podataka nebalansirana, podela na trening, validacioni i testni skup izvedena je **sa stratifikacijom**. Na taj način se obezbeđuje da svaki podskup zadrži sličan odnos filmova po žanrovima kao u celokupnom skupu, što smanjuje rizik od pristrasnih procena performansi modela.

4. Pretprocesiranje podataka

Za algoritme **Naivni Bajes** i **K najbližih suseda (KNN)** neophodno je detaljno pretprocesiranje teksta:

- **Uklanjanje interpunkcije** – eliminišu se znakovi koji ne doprinose semantičkom značenju (npr. tačke, zarezi, znakovi uzvika...)
- **Pretvaranje reči u mala slova (lowercase)** - pretvaranje u mala slova radi doslednosti (npr. "Film" i "film" tretiraju se isto)
- **Uklanjanje stop reči** – filtriraju se učestale reči (npr. *the*, *is*, *and*) koje ne nose informaciju o žanru. Koristi se unapred definisana lista učestalih reči na engleskom jeziku. Sve reči iz teksta koje se nalaze u toj listi se izbacuju.
- **Tokenizacija** – tekst se deli na pojedinačne reči
- **POS tagging i lematizacija** – reči se svrstavaju u gramatičke kategorije (imenice, glagoli, pridevi), a zatim svode na osnovni oblik (*lemma*).

Lematizacija svodi reči na njihov osnovni oblik koristeći gramatičku kategoriju. Primer:

reč *running* (glagol) postaje *run*,

reč *better* (pridev) postaje *good*.

Za određivanje gramatičke kategorije koristi se mapiranje oznaka sa standardnog POS taggera u oblik koji lematizer prepoznaje.

Za BERT model nije potrebno eksplicitno pretprocesiranje, jer BERT koristi sopstveni tokenizer i već je u fazi pretreniranja naučio semantičke i sintaktičke odnose između reči.

5. Metodologija

Plan je primena više algoritama mašinskog učenja radi upoređivanja tačnosti na problemu klasifikacije žanrova filmova. Algoritmi koje će se koristiti su: Naivni Bajes, K najbližih suseda (KNN) i i transformer model baziran na BERT arhitekturi.

Za Naivni Bajes i KNN koristi se TF-IDF (*Term Frequency – Inverse Document Frequency*) reprezentacija opisa filmova. TF-IDF predstavlja matricu dimenzija broj opisa $\times$ broj jedinstvenih reči iz rečnika kreiranog na osnovu trening skupa:

- Svaka instanca (opis filma) je predstavljen redom u matrici
- Svaka kolona odgovara jedinstvenoj reči iz rečnika.
- Vrednosti u ćelijama predstavljaju TF-IDF skor, koji kombinuje učestalost reči u opisu i njenu retkost u celokupnom skupu.

Rečnik se formira isključivo na osnovu trening skupa. Pre dodavanja reči u rečnik, tekst opisa filmova prolazi kroz proces pretprocesiranja. Svaka jedinstvena reč koja se pojavi u ovom pretprocesiranom trening skupu se uključuje u rečnik. Na osnovu tog rečnika se kreira TF-IDF matrica, gde redovi predstavljaju filmove iz trening skupa, a kolone odgovaraju jedinstvenim rečima iz rečnika. Konačne dimenzije matrice su **broj instanci trening skupa $\times$ broj reči pronađenih u rečniku**.

Eventualna izmena: Da bi se smanjila dimenzionalnost i izbegla previše retka (sparse) matrica, mogu se koristiti samo najinformativnije reči, npr. top 1000 reči prema kriterijumu učestalosti (npr. po vrednosti TF-IDF skora).

Ako se neka reč iz testnog skupa ne nalazi u rečniku trening skupa, njen TF-IDF skor se tretira kao 0, što rešava problem nepoznatih reči.

BERT koristi sopstveni tokenizer i već naučene semantičke i sintaktičke odnose između reči. Svaki opis filma se direktno prosleđuje tokenizer-u, koji pretvara tekst u niz tokena i pripadajuće embeddinge koje model koristi kao ulaz.

1. Naivni Bayes

Naivni Bajes je jednostavan i efikasan algoritam za klasifikaciju teksta koji pretpostavlja da su reči unutar opisa nezavisne. Za predstavljanje teksta koristi se TF-IDF metoda. Ovi vektori služe kao ulaz Naivnom Bajesu, dok se hiperparametar α koristi za Laplace smoothing – on ublažava problem reči koje se nisu pojavile u trening skupu određene klase, tako da model ne dodeljuje verovatnoću nula tim rečima.

2. K najbližih suseda

Za k najbližih suseda svaki opis filma se predstavlja kao TF-IDF vektor, gde svaka komponenta vektora odražava značaj pojedinačne reči u opisu u odnosu na ceo skup podataka. Ovi vektori omogućavaju određivanje sličnosti između opisa i identifikovanje najbližih primera iz trening skupa. Klasa se određuje prema najčešće zastupljenim klasama među k najbližih suseda. Za računanje rastojanja biće testirane različite metrike, dok će optimalna vrednost hiperparametra k biti određena korišćenjem validacionog skupa.

3. Transformer model baziran na BERT arhitekturi

BERT je unapred treniran na velikim korpusima, što omogućava razumevanje značenja reči u zavisnosti od konteksta u kojem se pojavljuju. Na osnovu toga model može da predvidi žanr filma direktno iz teksta, bez dodatnog pretprocesiranja.

Predviđeni pristupi za obuku:

- Fine-tuning - prilagođavanje poslednja dva sloja BERT modela na našem skupu opisa filmova, tako da model dodatno uči obrasce specifične za naš problem klasifikacije žanrova, a pritom zadržava prethodno naučeno znanje iz velikih korpusa kako se ne bi izgubila opšta semantička i sintaktička sposobnost modela. Za obuku se koriste AdamW optimizator i CrossEntropyLoss funkcija gubitka. Vrednosti hiperparametara stopa učenja (*learning rate*), broj epoha, batch size određuju se eksperimentisanjem i poređenjem performansi na validacionom skupu, dok se takođe koristi *early stopping* – prekid obuke ukoliko se validacioni gubitak ne poboljša tokom određenog broja epoha.
- Bez fine-tuning – BERT model se koristi za generisanje kontekstualnih reprezentacija opisa filmova, pri čemu se težine samog BERT modela ne menjaju. Na dobijene reprezentacije dodaje se linearni klasifikator koji uči da predviđa žanr na osnovu ovih reprezentacija. Linearni sloj se trenira na trening skupu, optimizujući funkciju gubitka CrossEntropyLoss, dok BERT reprezentacije služe kao fiksne reprezentacije koje prenose semantičko i sintaktičko znanje iz velikih korpusa.

6. Način evaluacije

Pošto je ovo problem višeklasne klasifikacije, može se izračunati F mera za ceo problem, i to:

1. Makro (*macro*) F mera - aritmetička sredina za svaku F meru (ovo se radi kada su sve klase podjednako važne).
2. Mikro (*micro*) F mera - spajanje sve u jednu matricu, jer ovde dominiraju klase koje su frekventnije.

7. Tehnologije

Python se koristi kao programski jezik, dok se za obradu podataka i implementaciju algoritama koriste biblioteke **scikit-learn**, **PyTorch** i **NLTK**.

8. Literatura

[1] ImGowthamG. (2024). Movie Genre Classification. Preuzeto sa:

<https://www.kaggle.com/code/imgowthamg/movie-genre-classification/output>

[2] Materijal sa predavanja

[3] Stanford CS224N. *NLP with Deep Learning | Winter 2020 | BERT and Pretrained Language Models*. YouTube. Preuzeto sa: https://www.youtube.com/watch?v=knTc-NQsJKA&utm_source=chatgpt.com